

Projet modélisation du risque

Davy TORRO Master 2 Analyse des risques bancaires

15-04-2024

```
{r setup, include=FALSE} knitr::opts_chunk$set(echo = TRUE)
install.packages("e1071")
library(e1071)
if (!requireNamespace("readxl", quietly = TRUE)) { install.packages("readxl") }
library(readxl)
```

Lecture du fichier

```
credits <- read_excel(file.choose())
```

Afficher les premières lignes pour vérifier que le contenu est correct

```
head(credits)
```

La sortie :

```
`Epargne retraite` `Risque de défaut` Type_produit nbre_conseils nbre_virements Sexe Livret_A Age Etudes Revenus
<chr> <chr> <chr> <dbl> <dbl> <chr> <chr> <dbl> <dbl> <dbl>
1 oui oui C 0 1 H oui 31 5 421
2 oui oui C 4 2 F oui 34 2 500
3 oui oui C 0 2 F oui 30 5 1255
4 oui oui C 1 2 F oui 32 5 2400
5 oui oui C 0 1 F oui 28 5 2654
6 oui oui A 0 2 F oui 30 5 1500
# i 1 more variable: `Satisfaction Client` <chr>
```

Nous avons nos données prêtes à être examiner.

Notre tableau présente différentes variables comme les profils des clients et leur niveau de satisfaction globale sur la banque. Avec notre expertise, nous allons dans un premier temps expliquer et prévoir la satisfaction des clients par rapport aux différentes caractéristiques des clients puis nous effectuerons la prévision du risque de défaut des clients à l'aide de multiples méthodes.

Analyse des données

Tout d'abord nous allons observer les tendances générales de nos données

```
summary(credits)
```

nbre_conseils	nbre_virements
Min. : 0.000	Min. : 0.00
1st Qu.: 0.000	1st Qu.: 2.00
Median : 1.000	Median : 10.00
Mean : 2.637	Mean : 19.20
3rd Qu.: 4.000	3rd Qu.: 24.75
Max. : 13.000	Max. : 104.00

Age	Etudes	Revenus
Min. : 19.0	Min. : 0.000	Min. : 0
1st Qu.: 29.0	1st Qu.: 0.050	1st Qu.: 1000
Median : 32.0	Median : 2.000	Median : 2450
Mean : 37.1	Mean : 2.367	Mean : 2712
3rd Qu.: 45.0	3rd Qu.: 5.000	3rd Qu.: 4000
Max. : 66.0	Max. : 8.000	Max. : 9000

On constate que dans notre échantillon, le profil moyen est celui d'une personne âgée de 32 ans dotée de 2 années d'études supérieures effectuant 19 virements avec un revenu situé autour de 2700 euros recevant un nombre de conseil proche de 3.

Nous pouvons effectuer une régression logistique afin de mettre en valeurs les résultats sur la satisfaction et les risques de défauts des clients.

Nous allons d'abord transformer les oui/non de la variable risque de défaut en 0 pour oui et 1 en non afin de pouvoir effectuer notre analyse

Recodage de 'oui'/'non' en 0/1 pour 'Risque de défaut'

```
credits$Risquedefaut <- ifelse(creditsRisque de défaut == "oui", 1, 0)
```

```
fitdefault = glm(formula = Risque de défaut ~ Age + Revenus + Etudes, family = binomial(link="logit"),
data = credits)
```

```
summary(fitdefault)
```

On obtient donc ceci :

```
Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept) 34.250354  14.534014   2.357  0.0184 *
Age         -0.591941   0.255446  -2.317  0.0205 *
Revenus      -0.012878   0.005923  -2.174  0.0297 *
Etudes        3.780164   1.783146   2.120  0.0340 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 141.049  on 101  degrees of freedom
Residual deviance:  13.532  on  98  degrees of freedom
AIC: 21.532

Number of Fisher Scoring iterations: 11
```

De par ses résultats, on observe dans un premier temps que tous les coefficients sont significatifs au seuil de 5%. De plus, on constate que l'âge et les revenus ont des effets négatifs sur le risque de défaut, ce qui signifie que plus un individu est âgé et/ou possède un patrimoine financier plus élevé, son risque de défaut n'est pas

ou peu observée. Notons également qu'il y a une corrélation positive entre le nombre d'année d'études et le risque de défaut, cela peut-être le lien direct avec l'endettement ou le faible revenu que l'individu perçoit durant cette période.

Notre régression est donc sur la bonne voie car il est plutôt cohérent.

Faisons de même pour la variable satisfaction client avec 0 comme mécontent et 1 comme point positif

Définir des mots-clés pour la satisfaction

```
mots_satisfaction <- c("satisfait", "bon", "excellent", "heureux", "content", "positif", "franchement", "top", "trading", "bien", "parfait", "cool", "conseille", "recommande", "qualité", "adore")
```

Définir des mots-clés pour l'insatisfaction

```
mots_insatisfaction <- c("mécontent", "mauvais", "problème", "négatif", "pas content", "pas satisfait", "bidon", "nul", "voleurs", "honte", "scandaleux", "gogols", "déçu", "jamais", "rien", "inexistante", "retard", "deçu", "marre", "impossible", "grosse", "fous", "fatigant")
```

Fonction pour coder la satisfaction en binaire

```
coder_satisfaction <- function(texte) { if (any(sapply(mots_satisfaction, grepl, texte))) { return(1) } else if (any(sapply(mots_insatisfaction, grepl, texte))) { return(0) } else { return(NA) } }
```

Appliquer la fonction pour recoder la variable

```
creditsSatisfaction_binaire <- sapply(creditsSatisfaction_Client, coder_satisfaction)
```

Application de la regression logistique

```
fitsatisfaction = glm(formula = Satisfaction_binaire ~ Age + Revenus + Etudes, family = binomial(link="logit"), data = credits)
```

```
summary(fitsatisfaction)
```

On obtient donc :

```
Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept) -3.2746891  1.3429388  -2.438  0.01475 *
Age           0.0599476  0.0365664   1.639  0.10113
Revenus       0.0013457  0.0004495   2.994  0.00275 **
Etudes       -0.0703370  0.1756052  -0.401  0.68876
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 86.987  on 74  degrees of freedom
Residual deviance: 49.338  on 71  degrees of freedom
(27 observations effacées parce que manquantes)
AIC: 57.338


Number of Fisher scoring iterations: 7
```

Les résultats nous indique que les individus avec des revenus élevés donnent globalement des notes satisfaisantes tandis que ceux qui ont des revenus moins élevés sont beaucoup plus déçus des services proposés, cela est

peut-être due à l'accessibilité des produits offerts et des services beaucoup plus élargies pour les individus plus aisés.


Vision des effets marginaux

```
plot(fitdefault$effects)
```



Aucune dispersion n'est notée ici, synonyme de bon signe, de plus de la non dispersion on constate que les résidus sont centrés autour de 0, cela témoigne de la précision des prédictions qui se rapproche des valeurs réelles (surapprentissage ?)

```
plot(fitsatisfaction$effects)
```



Ici les résidus sont beaucoup plus dispersés même si sur les 50 premières observations on constate une certaine homogénéité malgré des points aberrants.

Toutefois, afin de vérifier la bonne qualité des résidus, garantissant la bonne qualité du modèle, nous irons plus loin dans l'affirmation de la qualité de notre analyse.

Tester la qualité des modèles

```
install.packages("pscl")  
library(pscl)  
pR2(fitdefault)  
pR2(fitsatisfaction)
```

Sorties

```
> pR2(fitdefault)  
fitting null model for pseudo-r2  
      llh      llhNull      G2      McFadden      r2ML      r2CU  
-6.7660579 -70.5244399 127.5167640 0.9040608 0.7135423 0.9524909  
>  
> pR2(fitsatisfaction)  
fitting null model for pseudo-r2  
      llh      llhNull      G2      McFadden      r2ML      r2CU  
-24.6689828 -43.4936379 37.6493101 0.4328140 0.3946756 0.5749428  
> |
```

Pour le risque de défaut, on considère qu'une majeure partie du modèle (71%) justifie la variable, la qualité du modèle est excellent

Pour la satisfaction client, le modèle est correctement ajusté également même si le modèle n'explique pas 50% de la variable.

Le modèle est donc d'une bonne qualité si l'on croit ces facteurs même si il faut tenir une certaine rigueur et continuer la validité de l'analyse.

Prédiction de la satisfaction clientèle

Calcul des odds ratios

```
exp(coef(fitsatisfaction))  
> exp(coef(fitsatisfaction))  
(Intercept)      Age      Revenus      Etudes  
0.03782863 1.06178096 1.00134658 0.93207964
```

Tester tour à tour une variable

```
model2 = drop1(fitsatisfaction, test = "Chisq")  
model2
```

Single term deletions

```
Model:
Satisfaction_binaire ~ Age + Revenus + Etudes
      Df Deviance    AIC    LRT Pr(>Chi)
<none>      49.338 57.338
Age       1    52.330 58.330  2.9923   0.08366 .
Revenus   1    74.852 80.852 25.5141 4.392e-07 ***
Etudes    1    49.500 55.500  0.1619   0.68744
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Simplification du modèle par la méthode stepwise

```
model3 = step(fitsatisfaction)
```

Start: AIC=57.34

```
Satisfaction_binaire ~ Age + Revenus + Etudes
```

```
      Df Deviance    AIC
- Etudes  1    49.500 55.500
<none>      49.338 57.338
- Age     1    52.330 58.330
- Revenus 1    74.852 80.852
```

Step: AIC=55.5

```
Satisfaction_binaire ~ Age + Revenus
```

```
      Df Deviance    AIC
<none>      49.500 55.500
- Age     1    52.413 56.413
- Revenus 1    75.044 79.044
```

```
model3
```

```
> model3
```

```
Call: glm(formula = Satisfaction_binaire ~ Age + Revenus, family = binomial(link = "logit"),
  data = credits)
```

Coefficients:

```
(Intercept)      Age      Revenus
-3.368598      0.058881      0.001318
```

```
Degrees of Freedom: 74 Total (i.e. Null); 72 Residual
(27 observations effacées parce que manquantes)
```

```
Null Deviance:      86.99
```

```
Residual Deviance: 49.5      AIC: 55.5
```

Préparation pour la prévision avec une partition

```
n = nrow(credits) credits_shuffled = credits[sample(1:n, n),]
partition = sample(2, nrow(credits_shuffled), replace = TRUE, prob = c(0.8, 0.2))
```

Création des ensembles train/test

```
credits_train = credits_shuffled[partition == 1,] credits_test = credits_shuffled[partition == 2,]
```

Entraînement sur l'échantillon

```
fitsatisfaction_train = glm(formula = Satisfaction_binaire ~ Age + Revenus + Etudes, family =
binomial(link = "logit"), data = credits_train)
```

Prévision sur l'échantillon test

```
predictions = predict(fitsatisfaction_train, newdata = credits_test, type = "response")
```

Pour obtenir des probabilités :

```
predictions = predict(fitsatisfaction_train, newdata = credits_test, type = "response")
head(predictions)
```

Visualisation des premières prédictions du modèle

```
> predictions = predict(fitsatisfaction_train, newdata = credits_test, type
> head(predictions) # pour visualiser les premières prédictions du modèle
      1      2      3      4      5      6
0.43312601 0.33946407 0.40911101 0.99457518 0.97929328 0.09215732
```

Prédiction :

```
predictions_binary = as.numeric(predictions > 0.5)
predictions_binary
```

```
> predictions_binary
[1] 0 0 0 1 1 0 1 1 1 1 1 0 0 1 1 0 1 1 1 1 1
> # 2) Comparer la prévision 0/1 avec les valeurs observées 0/1 en
> # faisant un tableau de contingence
```

Comparer la prévision avec les valeurs observées

```
table(Reference = credits_test$Satisfaction_binaire, Predicted = predictions_binary)
```

	Predicted	
Reference	0	1
0	2	1
1	2	9

Figure 1:

```
pls$predictions_binary
```

Faisons de même pour le risque de défaut

Calcul des odds ratios pour le modèle risque de défaut

```
exp(coef(fitdefaut))
      (Intercept)      Age      Revenus      Etudes
7.494447e+14 5.532523e-01 9.872042e-01 4.382323e+01
```

Tester l'importance de chaque variable explicative individuellement (drop1)

```
model_defaut2 = drop1(fitdefaut, test = "Chisq")
```

```
model_defaut2
```

```
Model:
`Risque de défaut` ~ Age + Revenus + Etudes
      Df Deviance      AIC      LRT Pr(>Chi)
<none>      13.532  21.532
Age      1   35.037  41.037  21.505 3.529e-06 ***
Revenus  1  119.659 125.659 106.127 < 2.2e-16 ***
Etudes   1   29.076  35.076  15.544 8.063e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Simplification du modèle par la méthode stepwise

```
model_defaut3 = step(fitdefaut)
```

```
model_defaut3
```

```
Call: glm(formula = `Risque de défaut` ~ Age + Revenus + Etudes, family = binomial(link = "logit"),
  data = credits)
```

```
Coefficients:
(Intercept)      Age      Revenus      Etudes
 34.25035    -0.59194    -0.01288     3.78016

Degrees of Freedom: 101 Total (i.e. Null); 98 Residual
Null Deviance:      141
Residual Deviance: 13.53      AIC: 21.53
```

Comme observer précédemment, on observe une corrélation négative entre l'âge ainsi que le revenu par rapport au risque de défaut, ce qui confirme la cohérence de notre modèle

Préparation pour la prévision

```
n = nrow(credits)
```

```
credits_shuffled = credits[sample(1:n, n),]
```

Mélanger les données

```
partition2 = sample(2, nrow(credits_shuffled), replace = TRUE, prob = c(0.8, 0.2))
```

Création des ensembles train/test

```
credits_train = credits_shuffled[partition == 1,]
```

```
credits_test = credits_shuffled[partition == 2,]
```


Entraînement (estimation) sur l'échantillon train pour la variable 'Risque de défaut'

```
fitdefault_train = glm(formula = Risque de défaut ~ Age + Revenus + Etudes, family = binomial(link = "logit"), data = credits_train)
```

Prévision sur l'échantillon test

Pour obtenir des prédictions :

```
predictions_default = predict(fitdefault_train, newdata = credits_test, type = "response")
```

Pour obtenir des probabilités :

```
predictions_default = predict(fitdefault_train, newdata = credits_test, type = "response")
```

```
head(predictions_default)
```

```
> head(predictions_default)
      8      73      11      9      66      84
8.609934e-01 9.729081e-01 8.434310e-09 9.998692e-01 8.931388e-01 9.997744e-01
> |
```

Transformer notre prévision en variables binaires 0/1 :

```
predictions_default_binary = as.numeric(predictions_default > 0.5)
```

```
predictions_default_binary
```

```
> predictions_default_binary
[1] 1 1 0 1 1 1 1 0 1 1 0 0 1 1 0 0
~ |
```

Comme on peut le voir de manière générale, la tendance pousse à obtenir un plus grand nombre de client plus proche d'avoir un risque de défaut que non. Cela nous amène à reconsidérer comme les analyser et les accompagner dans leur démarche pour qu'il s'éloigne de ce périmètre de défaut.

Comparer la prévision 0/1 avec les valeurs observées 0/1 en faisant un tableau de contingence

```
table(Reference = credits_test$Risque de défaut, Predicted = predictions_default_binary)
```

```
> table(Reference = cr
      Predicted
Reference 0  1
      0  6  0
      1  0 10
```

Nous pouvons observer aucun faux positif ni aucun faux négatif résultant dans notre modèle. La tendance montrée plus haut est réaliste.

Cross-validation des résultats

La cross-validation permet de valider la qualité de la méthodologie employée, ainsi elle permet de confirmer la structuration des données.

```
fitdefault = glm(formula = Risque de défaut ~ Age + Revenus + Etudes, family = binomial(link="logit"), data = credits, CV = TRUE)
```

```
fitsatisfaction = glm(formula = Risque de défaut ~ Age + Revenus + Etudes, family = binomial(link="logit"), data = credits, CV = TRUE)
```

```
summary(fitdefault)
```

```
summary(fitsatisfaction)
```

Afin de renforcer notre analyse et prédire nos variables, on pourrait utiliser une méthodologie sous forme d'arbre.

Méthodologie en arbre

```
n = nrow(credits)
```

```
credits_random = credits[sample(1:n, n),]
```

Mélange des données de façon aléatoire

```
partition = sample(2, nrow(credits_random), replace = TRUE, prob = c(0.8, 0.2))
```

Création des ensembles de données train/test

```
credits_train = credits_random[partition == 1,]
```

```
credits_test = credits_random[partition == 2,]
```

Fonction pour calculer le taux d'erreur

```
error_rate = function(yobs, ypred) { mc = table(yobs, ypred)
```

```
err = 1 - sum(diag(mc)) / sum(mc)
```

```
return(err) }
```

Installation et chargement des packages nécessaires pour l'arbre de décision

```
if (!requireNamespace("rpart", quietly = TRUE)) { install.packages("rpart") }
```

```
if (!requireNamespace("rpart.plot", quietly = TRUE)) { install.packages("rpart.plot") }
```

```
install.packages("rpart")
```

```
install.packages("rpart.plot") library(rpart)
```

```
library(rpart.plot)
```

Construction de l'arbre de décision pour 'Risque de défaut'

```
arbre_default = rpart(Risque de défaut ~., data = credits_train)
```

```
rpart.plot(arbre_default)
```

```
arbre_default
```

```
pred_default = predict(arbre_default, newdata = credits_test, type = "prob")
```

```
pred_default_bin = as.numeric(pred_default[, "1"] > 0.5)
```

Matrice de confusion et taux d'erreur pour 'Risque de défaut'

```
table(reference = credits_test$Risque de défaut, pred_default_bin)
```

```
print(error_rate(credits_test$Risque de défaut, pred_default_bin))
```

Construction de l'arbre de décision pour 'Satisfaction'

```
arbre_satisfaction = rpart(Satisfaction ~., data = credits_train)
rpart.plot(arbre_satisfaction)
```

Prédiction sur l'échantillon test pour 'Satisfaction'

```
pred_satisfaction = predict(arbre_satisfaction, newdata = credits_test, type = "prob")
pred_satisfaction_bin = as.numeric(pred_satisfaction[, "1"] > 0.5)
```

Matrice de confusion et taux d'erreur pour 'Satisfaction'

```
table(reference = credits_test$Satisfaction, pred_satisfaction_bin)
print(error_rate(credits_test$Satisfaction, pred_satisfaction_bin))
```

Note

Dûe à une multitude d'erreurs logiciel dans les données qui se sont formatées et ne cessaient d'arrêter le logiciel, aucune sortie n'a pu fonctionner concernant l'arbre. Cela ne m'a donc pas permis d'exploiter les données et d'affirmer la méthodologie ou d'en réaliser l'analyse.

Conclusion

Pour conclure, nous pourrions proposer aux clients à faibles revenus des services qu'il s'agisse de conseils ou bien de produits bancaires et financiers, afin qu'ils puissent mieux gérer leurs épargnes ainsi que leurs revenus. Cela pourrait structurellement améliorer la satisfaction globale de l'ensemble de nos clients, généralement centrée sur ceux qui n'ont pas l'opportunité de profiter de tels services ! Ce bouquet de conseils et de propositions pourrait également leur permettre de capitaliser des sommes à travers nos comptes. Tout le monde est donc gagnant, et cela améliorerait leur solde. A terme, l'amélioration du solde permettrait une diminution du risque de défaut et une meilleure rentabilité pour nos déposants.